

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút): <https://youtu.be/1PhTeSB0dbw>
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/tuandm203/CS2205.JAN2026/blob/main/CS2205.JAN2026.DeCuong.FinalReport.Template.Slide.pdf>
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Đinh Minh Tuấn
MSHV: 250201097



- Lớp: CS2205.JAN2026
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 0
- Link Github:
<https://github.com/tuandm203/CS2205.JAN2026>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

NGHIÊN CỨU KIẾN TRÚC LAI CNN-TRANSFORMER KẾT HỢP KHÔNG GIAN 2.5D NHẪM NÂNG CAO ĐỘ CHÍNH XÁC PHÂN VÙNG CÁC CƠ QUAN KÍCH THUỐC NHỎ TRONG ẢNH CT Y KHOA

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

A STUDY ON HYBRID CNN-TRANSFORMER ARCHITECTURE INCORPORATING 2.5D SPATIAL INFORMATION FOR ENHANCING SMALL ORGAN SEGMENTATION IN MEDICAL CT IMAGES

TÓM TẮT *(Tối đa 400 từ)*

Trong lĩnh vực chẩn đoán hình ảnh y khoa, việc tự động hóa quá trình phân vùng đa cơ quan trên ảnh cắt lớp vi tính (CT) đóng vai trò nền tảng, là tiền đề quan trọng cho quá trình chẩn đoán, lập kế hoạch phẫu thuật và theo dõi bệnh lý. Tuy nhiên, các hệ thống hiện nay đối mặt với thách thức lớn khi xử lý và phân vùng các cơ quan có kích thước nhỏ. Các mô hình mạng thần kinh tích chập (CNN) truyền thống thường bị giới hạn bởi trường nhìn cục bộ (Local Receptive Field), khiến chúng khó liên kết các đặc trưng nằm cách xa nhau và dễ nhận diện sai hoặc bỏ sót các cơ quan nhỏ do bị các vùng mô lớn lấn át. Ngược lại, kiến trúc Transformer thuần túy dù có khả năng nắm bắt bối cảnh toàn cục nhờ cơ chế tự chú ý (self-attention) nhưng lại gặp khó khăn trong việc khôi phục các chi tiết ranh giới sắc nét và đòi hỏi chi phí tính toán khổng lồ.

Nghiên cứu này đề xuất một giải pháp : Kiến trúc lai CNN-Transformer kết hợp không gian 2.5D. Giải pháp cốt lõi là sự giao thoa giữa khả năng trích xuất đặc trưng hình học, chi tiết ranh giới mạnh mẽ của mạng CNN làm bộ trích xuất ban đầu, kết hợp với khả năng mô hình hóa các mối quan hệ không gian tầm xa của Transformer. Đặc biệt, thay vì chỉ dùng ảnh 2D thiếu hụt ngữ cảnh chiều sâu hoặc ảnh 3D tiêu tốn quá nhiều tài nguyên, hệ thống tích hợp không gian 2.5D thông qua việc tận dụng

thông tin từ các lát cắt kế cận. Kỹ thuật này giúp mô hình học sâu "nhìn thấy" sự xuất hiện và biến mất dần của khối tích cơ quan, từ đó kích hoạt lại các đặc trưng của đối tượng kích thước nhỏ (như thận, tuyến tụy) mà trước đó dễ bị các cơ quan lớn (như gan) lấn át.

GIỚI THIỆU (*Tối đa 1 trang A4*)

1. Xác định bài toán

Bài toán cốt lõi mà nghiên cứu này giải quyết là sự thiếu chính xác, ranh giới dự đoán không rõ ràng và tình trạng "bỏ sót" khi tự động phân vùng các cơ quan có kích thước nhỏ (như thận, tuyến tụy) trong không gian ảnh cắt lớp vi tính (CT) đa cơ quan.

Nguyên nhân chính đến từ việc các mô hình hiện tại gặp khó khăn trong việc cân bằng giữa trường nhìn cục bộ (local) và ngữ cảnh toàn cục (global), dẫn đến hiện tượng các cơ quan nhỏ bị lấn át bởi các cấu trúc mô lân cận lớn hơn (như gan).

- Đầu vào: Chuỗi dữ liệu ảnh cắt lớp vi tính (CT scan) y khoa, đặc trưng bởi các lát cắt 2D được xếp liên tiếp theo chiều sâu, thể hiện cấu trúc giải phẫu của đa cơ quan (tập dữ liệu Synapse).
- Đầu ra: Bản đồ phân vùng (segmentation mask) với độ chính xác cao cho từng cơ quan. Kết quả yêu cầu khắc phục triệt để sai số phân vùng ở các đối tượng nhỏ (Small ROI), đồng thời đảm bảo đường viền biên (boundary) sắc nét, mịn và sát với thực tế giải phẫu.

2. Tình hình nghiên cứu

Trong lĩnh vực phân vùng ảnh y tế, kiến trúc U-Net dựa trên mạng nơ-ron tích chập (CNN) truyền thống từng là tiêu chuẩn vàng nhờ khả năng trích xuất đặc trưng không gian tốt. Tuy nhiên, giới hạn bởi trường nhìn cục bộ (local receptive field), CNN gặp hạn chế trong việc nắm bắt mối quan hệ xa (long-range dependencies).

Thời gian gần đây, sự dịch chuyển sang các mô hình Transformer thuần túy (Pure Transformer, điển hình như Swin-Unet) đã giải quyết được bài toán bối cảnh toàn cục nhờ cơ chế tự chú ý (self-attention). Mặc dù vậy, Transformer thuần túy lại bộc lộ nhược điểm lớn trong việc khôi phục các chi tiết ranh giới sắc nét (làm tăng chỉ số

khoảng cách Hausdorff - HD95) và đòi hỏi chi phí tính toán rất lớn. Đáng chú ý, cả hai hướng tiếp cận này khi áp dụng trực tiếp trên ảnh 2D độc lập đều làm mất đi ngữ cảnh không gian theo trục chiều sâu, khiến các cơ quan nhỏ thường xuyên bị nhận diện sai hoặc gần như bị "xóa sổ" trong kết quả dự đoán. Các phương pháp chuyển sang dùng mô hình 3D thì lại đối mặt với rào cản về bộ nhớ tính toán khổng lồ.

3. Tính khoa học và tính mới của đề tài.

Tính khoa học: Nghiên cứu được xây dựng trên cơ sở tích hợp ưu điểm của hai nền tảng tiên tiến: khả năng trích xuất chi tiết hình học cục bộ tuyệt vời của mạng CNN và khả năng mô hình hóa mối quan hệ toàn cục của Transformer. Bên cạnh đó, đề tài áp dụng cơ sở toán học của xử lý không gian 2.5D (chiến lược ghép kênh - multi-channel từ các lát cắt 2D kế cận) để cung cấp cho mô hình ngữ cảnh không gian theo trục Z. Điều này cho phép hệ thống tính toán và đánh giá được quy luật xuất hiện và biến mất dần của khối tích vật lý mà không tốn kém tài nguyên như mạng 3D.

Tính mới: Điểm đột phá của đề tài nằm ở việc sử dụng không gian 2.5D kết hợp kiến trúc lai để giải quyết triệt để bài toán "đối tượng kích thước nhỏ" (Small ROI) vốn là thách thức lớn nhất của Swin-Unet. Trong khi các nghiên cứu hiện hành tập trung vào việc tinh chỉnh cơ chế attention phức tạp, giải pháp của đề tài thông minh ở chỗ: Bằng cách tận dụng thông tin từ các lát cắt kế cận (2.5D), AI được "nhìn thấy" phần khối tích của cơ quan nhỏ (như tuyến tụy, thận) đang dần xuất hiện, từ đó kích hoạt lại các đặc trưng bị lấn át bởi cơ quan lớn. Hướng tiếp cận này không chỉ giúp giảm triệt để sai số điểm ảnh ở cơ quan nhỏ (từ hạt hàng trăm pixel xuống mức tối thiểu) mà còn giúp cải thiện độ sắc nét biên (HD95) đáng kể với mức đánh đổi thời gian kiểm định (inference time) tăng thêm cực kỳ nhỏ, tạo ra một công cụ hỗ trợ chẩn đoán (CAD) tin cậy, ứng dụng thực tiễn cao trong lâm sàng.

MỤC TIÊU *(Viết trong vòng 3 mục tiêu)*

1. Nghiên cứu và xây dựng kiến trúc mạng lai CNN-Transformer kết hợp không gian 2.5D: Thiết kế thành công mô hình học sâu giao thoa giữa mạng tích chập CNN (trích xuất đặc trưng hình học cục bộ) và Transformer (mô hình hóa mối quan hệ toàn

cục). Tích hợp chiến lược ghép kênh đa chiều (multi-channel) từ các lát cắt kế cận để cung cấp ngữ cảnh không gian theo trục chiều sâu cho mô hình.

2. Nâng cao độ chính xác phân vùng và tối ưu hóa ranh giới các cơ quan kích

thước nhỏ: Giải quyết triệt để bài toán nhận diện sai hoặc bỏ sót các đối tượng kích thước nhỏ (Small ROI như tuyến tụy, thận) trên ảnh CT, thu hẹp tối đa sai số pixel giữa dự đoán và thực tế. Đồng thời, cải thiện độ sắc nét của đường viền biên (giảm chỉ số khoảng cách Hausdorff - HD95) mà vẫn đảm bảo tối ưu hóa chi phí thời gian kiểm định (inference time).

3. Thực nghiệm, đánh giá và định hướng ứng dụng lâm sàng: triển khai thử nghiệm, đối sánh hiệu năng của mô hình đề xuất với các kiến trúc tiên tiến hiện nay (như U-Net, Swin-Unet) trên tập dữ liệu ảnh CT đa cơ quan chuẩn hóa (như Synapse). Từ đó, hướng tới xây dựng một hệ thống hỗ trợ chẩn đoán bằng máy tính (CAD) tự động, có độ tin cậy cao, cải thiện, hướng tới phát triển một công cụ hỗ trợ chẩn đoán hình ảnh (CAD) tự động và có độ chính xác cao, góp phần nâng cao hiệu quả sàng lọc bệnh lý và tối ưu hóa quy trình làm việc lâm sàng tại các cơ sở y tế.

NỘI DUNG VÀ PHƯƠNG PHÁP

Trong nghiên cứu này, tôi đề xuất một phương pháp phân vùng học sâu hỗn hợp kết hợp giữa CNN và Transformer nhằm tối ưu hóa độ chính xác của việc nhận diện và phân vùng đa cơ quan tự động trên ảnh CT y khoa. Phương pháp này không chỉ dừng lại ở việc trích xuất các đặc trưng hình học cục bộ trên các lát cắt 2D đơn lẻ, mà còn đi sâu vào bản chất ngữ cảnh toàn cục và liên kết không gian khối tích (chiều sâu giải phẫu) của các cơ quan thông qua chiến lược 2.5D.

Nội dung 1: Thu thập, khảo sát và tiền xử lý chuyên sâu dữ liệu ảnh CT đa cơ quan

- Khai thác dữ liệu chuẩn: Sử dụng tập dữ liệu ảnh cắt lớp vi tính đa cơ quan chuẩn hóa (như Synapse Multi-organ CT Dataset) làm nền tảng.
- Tiền xử lý đặc thù y khoa : Thực hiện chuẩn hóa cường độ điểm ảnh thông qua cửa sổ dải giá trị Hounsfield (HU windowing) nhằm làm nổi bật độ tương phản

mô mềm ở vùng bụng.

Nội dung 2: Nghiên cứu và thiết kế kiến trúc mạng lai CNN-Transformer

- Xây dựng bộ trích xuất đặc trưng lai (Hybrid Encoder): Tích hợp mạng thần kinh tích chập (CNN) làm các tầng cơ sở để trích xuất các đặc trưng hình học không gian (local features) với độ phân giải cao, giúp giữ lại các chi tiết đường viền sắc nét của cơ quan.
- Khai thác ngữ cảnh toàn cục : Nhúng các khối Transformer (ví dụ: cơ chế Self-attention dạng cửa sổ trượt - Shifted Window) vào mạng lưới để mô hình hóa các mối liên hệ không gian tầm xa (long-range dependencies), khắc phục điểm mù của CNN khi phải xác định vị trí tương quan giữa các cơ quan nằm cách xa nhau.
- Thiết kế bộ giải mã (Decoder) : Sử dụng các kết nối tắt (skip-connections) linh hoạt để kết hợp các đặc trưng ngữ nghĩa mức cao (từ Transformer) và chi tiết hình học mức thấp (từ CNN), giúp tái tạo lại bản đồ phân vùng với độ phân giải gốc.

Nội dung 3: Đề xuất và tích hợp không gian 2.5D (Multi-channel Strategy) nhằm giải quyết bài toán đối tượng kích thước nhỏ (Small ROI)

- Xây dựng cơ chế đầu vào đa kênh: Thay vì đưa ảnh đầu vào là một lát cắt 2D độc lập I , nghiên cứu cấu trúc lại dữ liệu bằng cách ghép nối lát cắt mục tiêu với các lát cắt kế cận (ví dụ: $I(t-1)$, I , $I(t+1)$) tạo thành một đầu vào 2.5D.
- Khôi phục đặc trưng cơ quan nhỏ : Tận dụng dữ liệu đa kênh để mô hình học sâu có khả năng "nhìn thấy" quy luật xuất hiện hoặc biến mất dần theo trục Z (trục chiều sâu) của khối tích vật lý. Điều này đặc biệt quan trọng để kích hoạt lại các đặc trưng của các cơ quan kích thước rất nhỏ như tuyến tụy hay thận phải — vốn thường xuyên bị "xóa sổ" hoặc lấn át bởi tín hiệu quá mạnh từ cơ quan lớn như gan trong các mô hình 2D truyền thống.

Nội dung 4: Thử nghiệm, tối ưu hóa siêu tham số và đánh giá toàn diện

- Huấn luyện tối ưu: Thiết lập hàm mất mát hỗn hợp (Hybrid Loss) kết hợp giữa Dice Loss (chống lại sự mất cân bằng kích thước nền/cơ quan) và

Cross-Entropy Loss (tối ưu hóa độ chính xác điểm ảnh).

- Đánh giá chuyên sâu: So sánh trực tiếp hiệu năng của kiến trúc lai đề xuất với các mô hình tiêu chuẩn (U-Net) và mô hình hiện đại (Pure Transformer như Swin-Unet). Việc đánh giá không chỉ dựa trên độ bao phủ tổng thể mà tập trung bóc tách sự cải thiện ở từng cơ quan nhỏ cụ thể.

Phương pháp thực nghiệm

- Công cụ: Sử dụng ngôn ngữ Python với framework PyTorch để xây dựng, huấn luyện kiến trúc mạng học sâu (CNN-Transformer), kết hợp cùng các thư viện chuyên dụng cho ảnh y tế (như MONAI, SimpleITK hoặc NiBabel) để tiền xử lý và trích xuất không gian 2.5D từ dữ liệu CT (định dạng NIfTI).
- Dữ liệu đánh giá: Thử nghiệm trên bộ dữ liệu chuẩn hóa Synapse Multi-organ CT Dataset nhằm kiểm chứng khả năng phân vùng đa cơ cấu trúc giải phẫu, đặc biệt tập trung đánh giá khả năng khôi phục khối tích ở các cơ quan kích thước nhỏ (tuyến tụy, thận) khi đặt cạnh các cơ quan lớn (gan, lách).
- Chỉ số đánh giá: So sánh hiệu năng của phương pháp đề xuất với các kiến trúc cơ sở (chỉ dùng thuần CNN như U-Net hoặc thuần Transformer như Swin-Unet). Sử dụng hệ số tương đồng Dice (DSC) và khoảng cách Hausdorff (HD95) để chứng minh tỷ lệ giảm thiểu các trường hợp nhận diện thiếu (bỏ sót pixel/false negatives) đối với các đối tượng kích thước nhỏ (Small ROI), đồng thời đo lường thời gian kiểm định (Inference Time) để đảm bảo tính khả thi khi ứng dụng thực tế.

KẾT QUẢ MONG ĐỢI

Nghiên cứu kỳ vọng đạt được các kết quả định lượng cụ thể sau khi triển khai kiến trúc lai CNN-Transformer kết hợp không gian 2.5D trên bộ dữ liệu ảnh CT đa cơ quan chuẩn hóa (Synapse Dataset):

1. Nâng cao độ chính xác phân vùng

- Giảm tỷ lệ nhận diện thiếu (False Negatives): Kỳ vọng khắc phục triệt để tình trạng các cơ quan kích thước nhỏ (như thận, tuyến tụy) bị "xóa sổ" hoặc lẫn át

bởi các cơ quan lớn. Thu hẹp tối đa sai số điểm ảnh (pixels) giữa dự đoán và Ground Truth (kỳ vọng giảm từ mức sai lệch âm hàng trăm pixel xuống chỉ còn dưới 15 pixel cho mỗi mặt cắt).

- Độ tương đồng thể tích (Dice Similarity Coefficient - DSC): Cải thiện rõ rệt hệ số DSC trung bình trên tập test. Đặc biệt, tỷ lệ phân vùng chính xác (Segmentation Rate) trên nhóm các cơ quan có kích thước nhỏ (Small ROI) kỳ vọng tăng thêm 5-10% so với khi chỉ sử dụng mô hình 2D truyền thống (như thuần U-Net hoặc thuần Swin-Net).

2. Tối ưu hóa các chỉ số đo lường

- Chỉ số sắc nét ranh giới (HD95 Score): Kỳ vọng giảm chỉ số khoảng cách Hausdorff (HD95) xuống ít nhất 1.0 - 1.5 điểm (ví dụ: giảm từ mức 25.60 xuống 24.26). Điều này khẳng định các vùng phân vùng sẽ loại bỏ được các điểm ảnh lỗi nằm xa cơ quan thật, giúp đường viền dự đoán mịn màng và sát với thực tế giải phẫu hơn.
- Thời gian kiểm định (Inference Time Rate): Xác thực thành công tính khả thi về mặt tính toán của chiến lược ghép kênh (multi-channel 2.5D). Đảm bảo việc cung cấp ngữ cảnh chiều sâu chỉ làm tăng độ trễ kiểm định ở mức tối thiểu (kỳ vọng chỉ tốn thêm khoảng 15-20 giây cho mỗi chu kỳ), hoàn toàn nằm trong ngưỡng cho phép của các hệ thống lâm sàng và tối ưu hơn hẳn mạng 3D.

TÀI LIỆU THAM KHẢO (Định dạng DBLP)

- [1]. Cao, H., Wang, Y., Chen, J., Jiang, D., Zhang, X., Tian, Q., & Wang, M. (2021). Swin-UNET: UNet-Like Pure Transformer for Medical Image Segmentation. arXiv preprint arXiv:2105.05537. (Tài liệu cơ sở của đề án).
- [2]. Liu, Z., Lin, Y., Cao, Y., Hu, H., Wei, Y., Zhang, Z., Lin, S., & Guo, B. (2021). Swin Transformer: Hierarchical Vision Transformer Using Shifted Windows. Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV).
- [3]. Dosovitskiy, A., Beyer, L., Kolesnikov, A., et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. International Conference

on Learning Representations (ICLR).

[4]. Chen, J., Lu, Y., Yu, Q., et al. (2021). TransUNet: Transformers Make Strong Encoders for Medical Image Segmentation. arXiv preprint arXiv:2102.04306. [5].

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. Medical Image Computing and Computer-Assisted Intervention (MICCAI).

[5]. Zhou, Z., Siddiquee, M. R., Tajbakhsh, N., & Liang, J. (2018). UNet++: A Nested U-Net Architecture for Medical Image Segmentation. Medical Image Computing and Computer-Assisted Intervention (MICCAI) / Springer.

[6]. Hatamizadeh, A., Tang, Y., Nath, V., et al. (2022). UNETR: Transformers for 3D Medical Image Segmentation. Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV).

[7]. Liu, X., Hu, Y., & Chen, J. (2023). Hybrid CNN-Transformer model for medical image segmentation with pyramid convolution and multi-layer perceptron. Biomedical Signal Processing and Control.

[8]. Lợi, L. M., Thư, T. N. M., Hùng, N. T., An, H. Q., & Khang, P. N. (2024). Phát hiện và hiển thị 3D vùng bất thường trên ảnh MRI não với công dịch vụ Billow AISA. Tạp chí Khoa học Đại học Cần Thơ, Tập 60, Số 4A, tr. 29-37.

[9]. Lợi, L. M., Thư, T. N. M., An, H. Q., & Khang, P. N. (2024). Phát hiện vùng bất thường trên ảnh MRI não với mô hình Swin-Unet. Tạp chí Khoa học và Công nghệ - Đại học Thái Nguyên, Tập 229, Số 7, tr. 111-120.